

بازیابی-افزوده تولید (RAG)

پیاده‌سازی برای سیستم‌های هوش مصنوعی سازمانی راهنمای جامع

نسخه ۱.۰ | تهیه‌شده برای آزمون و ارزیابی سیستم‌های RAG | تاریخ: خرداد ۱۴۰۳

۱. مقدمه و پیشینه

تا لحظه‌ی آموزش محدود می‌شود و هیچ دسترسی مستقیمی به داده‌های جدید، اختصاصی یا سازمانی ندارند. دقیق و روان تولید کنند. با این حال، یکی از بزرگ‌ترین چالش‌های این مدل‌ها این است که اطلاعات آن‌ها نرم‌افزارهای هوشمند تبدیل شده‌اند. این مدل‌ها قادرند متن‌های طبیعی را درک کرده، تحلیل نمایند و پاسخ‌های در دنیای امروز، مدل‌های زبانی بزرگ (LLM) به یکی از پایه‌های اصلی مدل زبانی از این اطلاعات بازیابی‌شده به عنوان زمینه (context) استفاده می‌کند تا پاسخ نهایی را تولید نماید. مرحله‌ی اصلی است: در مرحله‌ی اول، اطلاعات مرتبط از یک پایگاه دانش بیرونی بازیابی می‌شود؛ در مرحله‌ی دوم، «بازیابی-افزوده تولید» یا RAG (Retrieval-Augmented Generation) مطرح شد. این رویکرد ترکیبی از دو برای رفع این محدودیت، رویکرد

پشتیبانی مشتری، تحلیل اسناد حقوقی، سیستم‌های پزشکی و هوش تجاری (BI) مورد استفاده قرار می‌گیرد. صورت گرفته است. امروزه این معماری در طیف وسیعی از کاربردها از جمله پرسش و پاسخ سازمانی، چت‌بات‌های معماری RAG اولین بار توسط لوئیس و همکاران در سال ۲۰۲۰ معرفی شد و از آن زمان تحولات گسترده‌ای در آن

۲. اجزای اصلی یک سیستم RAG

RAG از چندین مؤلفه‌ی کلیدی تشکیل می‌شود که هرکدام نقش مهمی در کیفیت نهایی پاسخ‌ها ایفا می‌کنند. یک سیستم

۲.۱ پردازش و بارگذاری اسناد (Document Ingestion)

ارائه شوند. در این مرحله، متن خام از اسناد استخراج شده، پاکسازی می‌شود و برای مراحل بعدی آماده می‌گردد. اسناد می‌توانند در قالب‌های مختلفی مانند HTML، Word، PDF، متن ساده یا حتی پایگاه‌های داده ساخت‌یافته اولین گام در ساخت یک سیستم RAG، آماده‌سازی و بارگذاری اسناد است.

(مثل سرصفحه، پاورقی، علائم خاص)، و شناسایی ساختار منطقی سند مانند عناوین، بخش‌ها و پاراگراف‌ها. توجه شود عبارتند از: کدگذاری نادرست کاراکترها (مخصوصا برای زبان فارسی)، حذف محتوای تکراری یا بی‌ربط مسائلی که در این مرحله باید به آن‌ها

۲.۲ تقسیم‌بندی متن (Chunking)

پنجره‌ی زمینه (context window) مدل‌های زبانی ضروری است. استراتژی‌های متداول تقسیم‌بندی عبارتند از: پس از بارگذاری اسناد، متن‌ها به قطعات کوچک‌تر به نام «chunk» تقسیم می‌شوند. این کار به دلیل محدودیت از کاراکتر یا توکن تقسیم می‌شود. این روش ساده است اما ممکن است جملات یا پاراگراف‌ها را از هم جدا کند. الف) تقسیم‌بندی بر اساس اندازه ثابت (Fixed-size chunking): در این روش، متن به قطعاتی با تعداد ثابتی معنایی مانند پاراگراف‌ها، بخش‌ها یا موضوعات ایجاد می‌شوند. این روش کیفیت بهتری دارد اما پیچیده‌تر است. ب) تقسیم‌بندی معنایی (Semantic chunking): در این رویکرد، قطعات بر اساس مرزهای ایجاد می‌شوند. مثلا اگر اندازه قطعه ۵۰۰ توکن باشد، ۵۰ توکن آخر هر قطعه در ابتدای قطعه بعدی تکرار می‌شود. با همپوشانی (Overlapping chunks): برای حفظ زمینه در مرزها، قطعات مجاور با مقداری همپوشانی ج) تقسیم‌بندی

۲.۳ تبدیل به بردار (Embedding)

OpenAI (که برای زبان فارسی نتایج بهتری می‌دهد) و مدل‌های بومی ایران مانند ParsBERT. مدل‌های embedding معروف عبارتند از: text-embedding-ada-002، Sentence-BERT، multilingual-e5. نمایانگر معنای متن در فضای برداری هستند و امکان مقایسه‌ی معنایی بین متن‌های مختلف را فراهم می‌کنند. مرحله‌ی بعدی، تبدیل هر قطعه از متن به یک بردار عددی چندبعدی است. این بردارها یا paraphrase-multilingual-mpnet-base-v2 برای این زبان پیشنهاد می‌شوند. عمومی عملکرد ضعیف‌تری روی متن‌های فارسی دارند. مدل‌هایی مانند intfloat/multilingual-e5-large برای زبان فارسی، انتخاب مدل embedding بسیار حیاتی است چرا که بسیاری از مدل‌های

۲.۴ پایگاه داده برداری (Vector Store)

Weaviate، Qdrant، (مناسب برای توسعه محلی)، Milvus (مقیاس‌پذیر) و FAISS (کتابخانه متن‌باز فیسبوک). سریع شباهت برداری را دارد. رایج‌ترین پایگاه‌های داده برداری عبارتند از: Pinecone (سرویس ابری)، Chroma بردارهای تولیدشده در یک پایگاه داده تخصصی ذخیره می‌شوند که قابلیت جستجوی

(HNSW یا IVF (Inverted File Index) استفاده می‌شود که جستجو را به صورت تقریبی (ANN) انجام می‌دهند. عمل می‌کنند. برای مقیاس‌های بزرگ، از الگوریتم‌هایی مانند Hierarchical Navigable Small World (Cosine Similarity) یا فاصله‌ی اقلیدسی (Euclidean Distance) معمولاً بر اساس فاصله‌ی کسینوسی (Cosine Similarity) یا فاصله‌ی اقلیدسی (Euclidean Distance) الگوریتم‌های جستجو در این پایگاه‌ها

۲.۵ بازیابی و رتبه‌بندی (Retrieval & Reranking)

قطعات در پایگاه داده برداری جستجو می‌شوند. در این مرحله، معمولاً k قطعه‌ی برتر (top-k) بازیابی می‌شوند. هنگامی که کاربر سؤالی مطرح می‌کند، سؤال نیز به بردار تبدیل شده و نزدیک‌ترین

را با دقت بیشتری ارزیابی و مرتب می‌کنند. این کار کیفیت نهایی پاسخ را به طور قابل توجهی بهبود می‌دهد. مدل‌های تخصصی‌تری مانند Cross-Encoder یا مدل‌های rerank آنتروپیک یا Cohere، قطعات بازیابی‌شده برای بهبود کیفیت بازیابی، می‌توان از مرحله‌ی رتبه‌بندی مجدد (reranking) استفاده کرد. در این مرحله،

۲.۶ تولید پاسخ (Generation)

معمولاً شامل سه بخش است: دستورالعمل سیستم (system prompt)، زمینه‌ی بازیابی‌شده و سؤال کاربر. ارسال می‌شود. مدل با استفاده از این اطلاعات، پاسخی جامع، دقیق و مستند تولید می‌کند. ساختار prompt در مرحله‌ی آخر، سؤال اصلی کاربر به همراه قطعات بازیابی‌شده به عنوان prompt به مدل زبانی بزرگ

۳. چالش‌های RAG برای زبان فارسی

پیاده‌سازی RAG برای زبان فارسی با چالش‌های خاصی روبرو است که در ادامه به مهم‌ترین آن‌ها اشاره می‌شود.

۳.۱ چندریختی متن فارسی

هنگام جستجو شود. برای رفع این مشکل، باید یک مرحله‌ی نرمال‌سازی متن قبل از تبدیل به بردار انجام شود. شود. همچنین «ی» و «ی» و «ئ» در برخی موارد معادل یکدیگر هستند. این موضوع می‌تواند منجر به عدم تطابق فارسی دارای اشکال مختلفی از نوشتار است. یک کاراکتر مانند «ک» می‌تواند به صورت «ك» (عربی) نیز نوشته زبان

۳.۲ اتصال کلمات و توکن‌بندی

این ویژگی باعث می‌شود توکن‌بندی دقیق نیاز به ابزارهای تخصصی مانند Hazm یا NLTK Persian داشته باشد. پیشوندها و پسوندها به کلمات متصل می‌شوند. مثلاً «کتاب‌هایم» ترکیبی از «کتاب» + «ها» + «ی» + «م» است. فارسی یک زبان چسبنده است که در آن

۳.۳ کمبود داده آموزشی

قرار می‌دهد. پروژه‌هایی مانند FaBERT، ParsBERT و mDeBERTa تلاش‌هایی برای پر کردن این خلأ هستند. در دسترس برای فارسی بسیار کمتر است. این امر کیفیت مدل‌های embedding و تولید متن را تحت تأثیر در مقایسه با انگلیسی، حجم داده‌های آموزشی

۳.۴ راست‌به‌چپ بودن

تکنیکال، باید اطمینان حاصل شود که تمام مراحل پردازش، ذخیره‌سازی و نمایش این ویژگی را در نظر می‌گیرند. متن فارسی در رابط‌های کاربری و گزارش‌ها نیازمند پشتیبانی از راست‌به‌چپ (RTL) است. در پیاده‌سازی‌های نمایش صحیح

۴. معیارهای ارزیابی RAG

ارزیابی کیفیت یک سیستم RAG از چند منظر انجام می‌شود:

۴.۱ دقت بازیابی (Retrieval Accuracy)

در k نتیجه اول، (MRR (Mean Reciprocal Rank و (NDCG (Normalized Discounted Cumulative Gain). مرتبط را بازیابی کند. شاخص‌های رایج عبارتند از: Precision@K (دقت در k نتیجه اول)، Recall@K (فراخوانی این معیار نشان می‌دهد که آیا سیستم توانسته است قطعات

۴.۲ کیفیت تولید (Generation Quality)

نیز به صورت خودکار ابعادی مانند answer relevancy، faithfulness و context precision را اندازه می‌گیرند. و همچنین ارزیابی انسانی (Human Evaluation) در این حوزه استفاده می‌شوند. چارچوب‌هایی مانند RAGAS کیفیت پاسخ نهایی تولیدشده توسط مدل زبانی را می‌سنجد. شاخص‌هایی مانند BLEU، ROUGE، BERTScore این معیار

۴.۳ صحت استناد (Faithfulness)

نداشته باشد. این ویژگی در کاربردهای حساس مانند پزشکی، حقوقی و مالی اهمیت بسیار بالایی دارد. که مدل پاسخی ارائه می‌دهد که واقعا از محتوای بازیابی‌شده پشتیبانی می‌شود و «توهم‌زایی» (hallucination) یکی از مهم‌ترین معیارها برای سیستم‌های RAG، اطمینان از این است

۵. معماری‌های پیشرفته RAG

۵.۱ Advanced RAG

است. در HyDE، ابتدا یک سند فرضی برای پرسش تولید می‌شود و سپس از آن برای جستجو استفاده می‌گردد. پرسش (Query Rewriting)، بازیابی چندمرحله‌ای (Multi-hop Retrieval) و ادغام نتایج چندین مدل بازیابی نسل پیشرفته‌تر RAG شامل تکنیک‌هایی مانند HyDE (Hypothetical Document Embeddings)، بازیابی

۵.۲ Agentic RAG

فرآیند تکرار شود. ابزارهایی مانند LangGraph و CrewAI امکان پیاده‌سازی چنین عامل‌هایی را فراهم می‌کنند. هوشمند (agent) تصمیم می‌گیرد که آیا بازیابی لازم است یا خیر، از کدام منابع بازیابی کند، و چند بار باید این در این معماری، یک عامل

۵.۳ GraphRAG

Knowledge Graph) یک رویکرد نوین است که در آن به جای ذخیره صرف قطعات متن، یک گراف دانش GraphRAG از منابع مختلف دارند بسیار مؤثر است (entities) از اسناد ساخته می‌شود. در این گراف، موجودیت‌ها (Graph) و روابط بین آن‌ها استخراج و ذخیره می‌شوند. این رویکرد برای پرسش‌هایی که نیاز به ترکیب اطلاعات

۶. پیاده‌سازی عملی با LangChain

یک نمونه‌ی ساده از پیاده‌سازی RAG یکی از پرکاربردترین چارچوب‌ها برای ساخت سیستم‌های LangChain. با این چارچوب ارائه می‌شود RAG است. در ادامه،

اسناد: از کلاس‌های loader مانند PyPDFLoader یا DirectoryLoader برای خواندن اسناد استفاده می‌شود. مرحله ۱ - بارگذاری

با تنظیم پارامترهای chunk_size و chunk_overlap متناسب با زبان فارسی استفاده می‌شود.

مرحله ۲ - تقسیم‌بندی: از کلاس RecursiveCharacterTextSplitter

و ذخیره‌سازی: بردارها با استفاده از مدل انتخابی ساخته شده و در Chroma یا FAISS ذخیره می‌شوند.

مرحله ۳ - Embedding

از RetrievalQA یا LCEL (LangChain Expression Language)، زنجیره‌ی کامل بازیابی و تولید تعریف می‌شود.

مرحله ۴ - ساخت زنجیره RAG: با استفاده

۷. کاربرد RAG در هوش تجاری

کاربران می‌توانند به جای نوشتن کوئری‌های پیچیده SQL یا MDX، سؤالات خود را به زبان طبیعی مطرح کنند. جذاب RAG، استفاده از آن در سیستم‌های هوش تجاری (Business Intelligence) است. در این کاربرد، یکی از کاربردهای

ابهام، سؤالات دقیق‌تری مطرح می‌کند. در نهایت، یک کوئری MDX ساخته شده و روی cube داده اجرا می‌گردد. فیلترهای مورد نظر را شناسایی می‌کند. سپس یک عامل ابهام‌زدایی (Disambiguation Agent) در صورت وجود اطلاعات (Extractor Agent) پردازش می‌شوند. این عامل ابعاد (dimensions)، معیارها (measures) و در سیستم‌هایی مانند CubeAgent، پرسش‌های فارسی کاربران ابتدا توسط یک عامل استخراج آنها به صورت پویا از روی schema استخراج شده و به عنوان زمینه (context) به عامل استخراج ارائه می‌شوند. در بارگذاری اطلاعات schema مکعب داده دارد. اطلاعاتی مانند نام ابعاد، سلسله مراتب، معیارها و توضیحات در این معماری، RAG نقش مهمی

۸. بهترین رویکردها و توصیه‌ها

و مطالعات انجام‌شده، توصیه‌های زیر برای ساخت یک سیستم RAG فارسی با کیفیت بالا پیشنهاد می‌شود: بر اساس تجربیات عملی

از کتابخانه‌هایی مانند Hazm برای نرمال‌سازی کاراکترها، جداسازی پیشوندها و پسوندها و رفع مشکل نیم‌فاصله. اول: سرمایه‌گذاری بر روی مرحله‌ی نرمال‌سازی متن فارسی. استفاده

مختلف روی مجموعه داده‌های تست فارسی و انتخاب مدلی که بهترین نتیجه را روی حوزه‌ی کاری شما دارد. دوم: آزمایش مدل‌های embedding

اندازه‌های کوچک‌تر (۲۵۶-۵۱۲ توکن) و برای متون روایی، اندازه‌های بزرگ‌تر (۵۱۲-۱۰۲۴ توکن) مناسب‌تر است. سوم: تنظیم دقیق اندازه قطعات (chunk size) متناسب با نوع محتوا. برای متون فنی با جملات کوتاه،

مرحله‌ی reranking برای بهبود کیفیت نتایج بازیابی، به خصوص برای پرسش‌های چندوجهی یا پیچیده. چهارم: پیاده‌سازی

evaluation) با سؤالات و پاسخ‌های طلایی (golden QA pairs) برای اندازه‌گیری و بهبود مستمر کیفیت سیستم. پنجم: طراحی یک مجموعه ارزیابی (set)

مانند Langfuse یا LangSmith برای ردیابی مکالمات، بررسی کیفیت بازیابی و شناسایی نقاط ضعف سیستم. ششم: پیاده‌سازی ابزارهای نظارت (observability)

۹. آینده RAG

RAG که نتایج را به صورت تدریجی ارائه می‌دهد؛ و RAG با حافظه بلندمدت که تاریخچه مکالمات را نگه می‌دارد. چندوجهی (Multimodal RAG) که قادر به پردازش تصاویر، جداول و نمودارها در کنار متن است؛ streaming فناوری RAG در حال تحول سریع است. برخی از جهت‌گیری‌های آینده عبارتند از: RAG سازمان‌هایی با حجم داده‌ی بسیار زیاد و نیاز به به‌روزرسانی مستمر اطلاعات، RAG همچنان ضروری خواهد بود. context) به صدها هزار توکن، ممکن است برخی کاربردهای RAG کم‌اهمیت‌تر شوند. با این حال، برای همچنین، با پیشرفت مدل‌های زبانی و افزایش پنجره زمینه آن‌ها (window) زبانی فارسی قوی‌تری توسعه یابند که کیفیت سیستم‌های RAG فارسی را به طور چشم‌گیری بهبود بخشند. در حوزه‌ی فارسی، انتظار می‌رود با رشد اکوسیستم هوش مصنوعی ایران، مدل‌های

۱۰. نتیجه‌گیری

عمومی مدل بهره می‌برند، بلکه به طور دقیق و مستند از دانش اختصاصی سازمان نیز استفاده می‌کنند RAG سازمان‌های واقعی را پر می‌کند. با استفاده از این رویکرد، می‌توان سیستم‌هایی ساخت که نه تنها از دانش یک معماری قدرتمند است که شکاف بین توانایی‌های مدل‌های زبانی بزرگ و نیازهای مطرح‌شده در این سند، می‌توان سیستم‌هایی با کیفیت بالا برای کاربران فارسی‌زبان طراحی و پیاده‌سازی کرد. درست ابزارها و مدل‌ها، و سرمایه‌گذاری مستمر در ارزیابی و بهبود کیفیت است. با رعایت اصول و توصیه‌های برای زبان فارسی، پیاده‌سازی موفق RAG نیازمند توجه ویژه به چالش‌های زبانی، انتخاب

RAG تهیه شده است. تمامی محتوا به زبان فارسی و با هدف پوشش طیف گسترده‌ای از موضوعات مرتبط با RAG نوشته شده است. این سند به عنوان نمونه داده برای آزمایش سیستم‌های